

FINAL PROJECT

Project-Based Intern : Data Scientist

Presented by Maya Indah Nurrohmah



Hai!
Perkenalkan aku

Maya Indah

Nurrohmah

Deskripsi Diri

Saya merupakan seorang *fresh graduate* Program Studi Matematika di Universitas Diponegoro. Saya senang berbagi dan berkolaborasi dengan orang lain, memecahkan masalah, dan dapat menyampaikan ide dengan baik.



Pengalaman



Mentee

*Program Data, Business Analytics, and Operations*Di Ruangguru

(Feb 2022 - Jul 2022)

Mempelajari bisnis *analytics*, bahasa pemrograman *Python* dan *SQL*, proses pengumpulan dan pemrosesan data, pembuatan visualisasi data, dan strategi bisnis yang baik bagi perusahaan.



Learn Basics & Data Analytics with Microsoft Excel for Begineers di Pintaar

(Tahun 2021)

Mempelajari dasar-dasar penggunaan excel untuk melakukan pengolahan data mulai dari impor data, pembersihan data, analisis deskriptif, regresi, dan korelasi



Case Study



Case Study

(Business Understanding)

Misalkan Data Scientist di Kalbe Nutritionals mendapatkan **project baru dari tim inventory** dan **tim marketing** dengan permintaan dari setiap tim sebagai berikut:

A. Tim Inventory

Permintaan:

Membantu memprediksi jumlah penjualan dari total keseluruhan produk Kalbe

Tujuan:

Mengetahui perkiraan *quantity* produk yang terjual





Case Study

(Business Understanding)

Misalkan Data Scientist di Kalbe Nutritionals dan sedang mendapatkan project baru dari tim inventory dan tim marketing dengan permintaan dari setiap tim sebagai berikut:

B. Tim Marketing

Permintaan:

Membuat customer segmentation

Tujuan:

Memberikan personalized promotion dan sales treatment kepada customer



Data Understanding



data_store

Column	Description	Column	Description
StoreID	Kode Unik Store	Туре	Modern Trade, General Trade
StoreName	Nama Toko	Latitude	Kode Latitude
GroupStore	Nama group	Longitude	Kode Longitude

data_transactions

Column	Description	Column	Description
TransactionID	Kode Unik Transaksi	Price	Harga Item (Rp)
CustomerID	No Unik Customer	Qty	Jumlah Item yang dibeli
Date	Tanggal transaksi	Total Amount	Price x Qty (Rp)
ProductID	Kode Unik Product	StoreID	Kode Unik Store

data_products

Column	Description
ProductID	Kode Unik Product
Product Name	Nama Product
Price	Harga dlm rupiah

data customer

Column	Description
CustomerID	No Unik Customer
Age	Usia Customer (Tahun)
Gender	Jenis Kelamin (0 Wanita, 1 Pria)
Marital Status	Married, Single (Blm menikah/Pernah menikah)
Income	Pendapatan per Bulan dalam Jutaan Rupiah

Data Pre-processing (Menyesuaikan Tipe Data dan Handle Missing Value)



data_store

```
# Melihat informasi data store
data store.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 14 entries, 0 to 13
Data columns (total 6 columns):
     Column
                Non-Null Count Dtvpe
     StoreID
                14 non-null
                                int64
                14 non-null
     StoreName
                                object
    GroupStore 14 non-null
                                object
                                object
    Type
                14 non-null
    Latitude
                14 non-null
                                object
     Longitude 14 non-null
                                obiect
dtypes: int64(1), object(5)
memory usage: 800.0+ bytes
```

Mengubah tipe data kolom StoreID

data store['StoreID'].astvpe("object")

data store['StoreID'] =

data store.info()

data_products

```
# Melihat informasi data products
data products.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10 entries, 0 to 9
Data columns (total 3 columns):
     Column
                  Non-Null Count Dtype
    ProductID
                   10 non-null
                                   object
    Product Name 10 non-null
                                   object
    Price
                   10 non-null
                                   int64
dtypes: int64(1), object(2)
memory usage: 368.0+ bytes
```

data transactions

Melihat informasi data transactions

```
data transactions.info()
         <class 'pandas.core.frame.DataFrame'>
        RangeIndex: 5020 entries, 0 to 5019
        Data columns (total 8 columns):
             Column
                           Non-Null Count Dtype
             TransactionID 5020 non-null
                                          object
             CustomerID
                           5020 non-null
                                         int64
             Date
                           5020 non-null
                                          object
             ProductID
                           5020 non-null
                                          object
             Price
                           5020 non-null
                                         int64
             0tv
                           5020 non-null
                                          int64
             TotalAmount
                           5020 non-null
                                         int64
             StoreID
                           5020 non-null
                                          int64
         dtypes: int64(5), object(3)
        memory usage: 313.9+ KB
# Mengubah Tipe Data
data transactions['TransactionID'] =
data transactions['TransactionID'].astvpe("object")
data transactions['CustomerID'] =
data transactions['CustomerID'].astype("object")
data transactions['StoreID'] =
data transactions['StoreID'].astype("object")
data transactions.info()
```

Data Pre-processing (Menyesuaikan Tipe Data dan Handle Missing Value)



data customer

```
<class 'pandas.core.frame.DataFrame'>
                                                   # Mengubah tipe data 'CustomerID' dan 'Gender' menjadi object
RangeIndex: 447 entries, 0 to 446
Data columns (total 5 columns):
                                                   data customer['CustomerID'] = data customer['CustomerID'].astype("object")
                                                   data_customer['Gender'] = data_customer['Gender'].astype("object")
    Column
                     Non-Null Count
                                     Dtype
                                                   data customer.info()
    CustomerID
                     447 non-null
                                     int64
    Age
                    447 non-null
                                     int64
                                                   # Menghapus nilai null
    Gender
                    447 non-null
                                     int64
    Marital Status 444 non-null
                                     object
    Income
                     447 non-null
                                     object
                                                   data customer = data customer.dropna()
dtypes: int64(3), object(2)
                                                   data customer.count()
memory usage: 17.6+ KB
                                                   CustomerID
                                                                       444
                                                   Age
                                                                       444
                                                   Gender
                                                                       444
                                                   Marital Status
                                                                       444
                                                   Income
                                                                       444
                                                   dtype: int64
```

Data Pre-processing (Menyesuaikan Tipe Data dan Handle Missing Value)



data_customer

Menampilkan umur customer termuda

data_customer[data_customer.Age == data_customer.Age.min()]

	CustomerID	Age	Gender	Marital Status	Income
127	128	0	1	Married	6,77

Menampilkan umur customer yang berusia kurang dari 18 tahun
data_customer[data_customer.Age < 18]</pre>

	CustomerID	Age	Gender	Marital Status	Income
11	12	2	1	Married	4,94
73	74	3	1	Married	5,09
127	128	0	1	Married	6,77

```
# Mengecualikan customer berusia 2,3,dan 0 tahun
data customer = data customer[data customer['Age'] >= 18]
data customer.info()
<class 'pandas.core.frame.DataFrame'>
Int64Index: 441 entries, 0 to 446
Data columns (total 5 columns):
                   Non-Null Count Dtype
    Column
    CustomerID
                  441 non-null
                                  obiect
                441 non-null
                                   int64
    Age
    Gender 441 non-null
                                   object
    Marital Status 441 non-null
                                   object
    Income
                   441 non-null
                                   object
dtypes: int64(1), object(4)
memory usage: 20.7+ KB
```

Data Pre-processing (Memeriksa Data Duplikat)



data store

Memeriksa data duplikat dalam dataset

duplicate_rows_data_store = data_store[data_store.duplicated()]
print('banyaknya baris yang terduplikat:', duplicate_rows_data_store.shape)

banyaknya baris yang terduplikat: (0, 6)

data_products

Memeriksa data duplikat dalam dataset

duplicate_rows_data_products = data_products[data_products.duplicated()]
print('banyaknya baris yang terduplikat:', duplicate rows data products.shape)

banyaknya baris yang terduplikat: (0, 3)

data_transactions

Memeriksa data duplikat dalam dataset

duplicate_rows_data_transactions = data_transactions[data_transactions.duplicated()]
print('banyaknya baris yang terduplikat:', duplicate_rows_data_transactions.shape)

banyaknya baris yang terduplikat: (0, 8)

data customer

Memeriksa data duplikat dalam dataset

duplicate_rows_data_customer = data_customer[data_customer.duplicated()]
print('banyaknya baris yang terduplikat:', duplicate_rows_data_customer.shape)

banyaknya baris yang terduplikat: (0, 5)

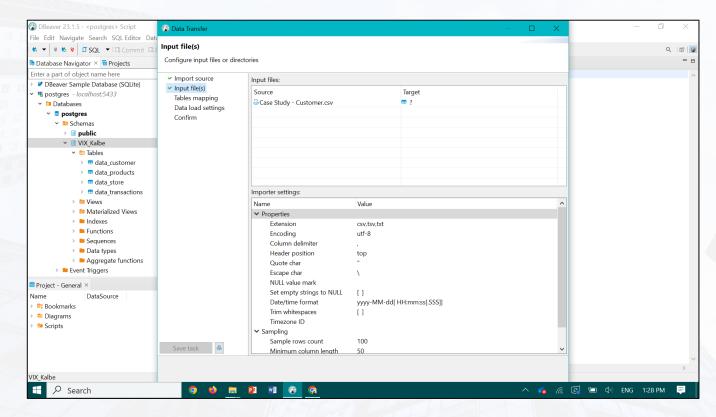
Dari masing-masing dataset, tidak ada data yang terduplikat



Challenge 1

Melakukan *data ingestion* ke dalam dbeaver

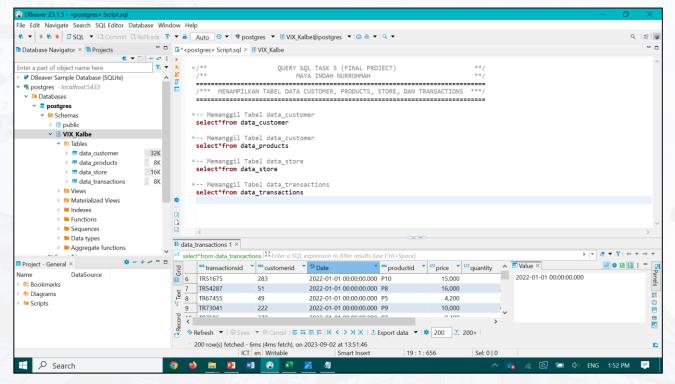
data ingestion adalah proses pemindahan data dari satu atau beberapa sumber Ke suatu penyimpanan yang nantinya akan disimpan dan dianalisis lebih lanjut





Membuat schemas baru >> Import data dalam menu Tables >> Import Sources >> Configure Table and Configure Structure >> Next >> Proceed





Setelah memasukan dan mengatur delimiter dari 4 dataset ke dalam dbeaver, tabel-table tersebut telah berhasil di import dalam dbeaver



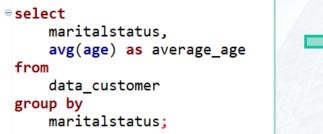
Challenge 2

Melakukan **exploratory data analysis** melalui dbeaver



Rata-Rata Umur Customer (berdasarkan Marital Status)

Query: Output:





maritalstatus T	¹²³ average_age
Single	29.3846153846
Married	43.4065281899

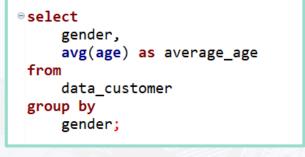
Jadi, diperoleh informasi bahwa:

- Rata-rata usia customer yang masih lajang (single) yaitu 29,4 tahun
- Rata-rata usia customer yang sudah menikah (Married) yaitu 43,4 tahun



Rata-Rata Umur Customer (berdasarkan Gender)

Query:



Output:

	gender •	¹²³ average_age ▼
1	1	39.824120603
2	0	40.326446281

Jadi, diperoleh informasi bahwa:

- Rata-rata usia customer laki-laki (kode 1) yaitu 39,8 tahun
- Rata-rata usia customer perempuan (kode 0) yaitu 40,3 tahun

on a.productid = c.productid;



```
/* Melakukan left join data_transactions dengan data_store dan data_products */
select*from data_transactions;
select*from data_store;
select*from data_products;
⊝select
    a.productid,
    c.productname,
    a.quantity,
    a.totalamount,
    a.storeid,
    b.storenama
from
    data transactions as a
left join data_store as b
   on a.storeid = b.storeid
left join data_products as c
```

	productid *	productname *	¹²³ quantity	123 totalamount	storeid *	storenama 🔻
1	P3	Crackers	4	30,000	12	Prestasi Utama
2	P9	Yoghurt	7	70,000	1	Prima Tendean
3	P1	Choco Bar	4	35,200	4	Gita Ginara
4	P1	Choco Bar	7	61,600	4	Gita Ginara
5	P9	Yoghurt	1	10,000	4	Gita Ginara
6	P10	Cheese Stick	1	15,000	5	Bonafid
7	P8	Oat	2	32,000	2	Prima Kelapa Dua
8	P5	Thai Tea	3	12,600	13	Buana
9	P9	Yoghurt	6	60,000	4	Gita Ginara
10	P7	Coffee Candy	2	18,800	14	Priangan
11	P4	Potato Chip	4	48,000	12	Prestasi Utama



Nama **Store** dengan **Total Quantity Terbanyak**

Query:

```
select
    storenama,
    sum(quantity) as totalquantity
from
    data_question3_question4
group by
    storenama
order by
    totalquantity desc;
```



Output:

<u> </u>	storenama *	123 total quantity
1	Lingga	2,777
2	Sinar Harapan	2,588
3	Prestasi Utama	1,395
4	Prima Kota	1,358
5	Buana	1,320
6	Prima Tendean	1,310
7	Prima Kelapa Dua	1,296
8	Harapan Baru	1,286
9	Bonafid	1,283
10	Priangan	1,239
11	Gita Ginara	1,236
12	Buana Indah	1,208

Jadi, terdapat 12 *store* yang ada dalam data dan *store* yang berhasil menjual *item* (*total quantity*) terbanyak yaitu Lingga dengan total item yang berhasil terjual (*total quantity*) sebanyak 2777 buah.



Nama **Produk Terlaris** dengan *Total Amount* Terbanyak

Query:

```
select
    productname,
    sum(totalamount) as totalamountfinal
from
    data_question3_question4
group by
    productname
order by
    totalamountfinal desc;
Output:
```

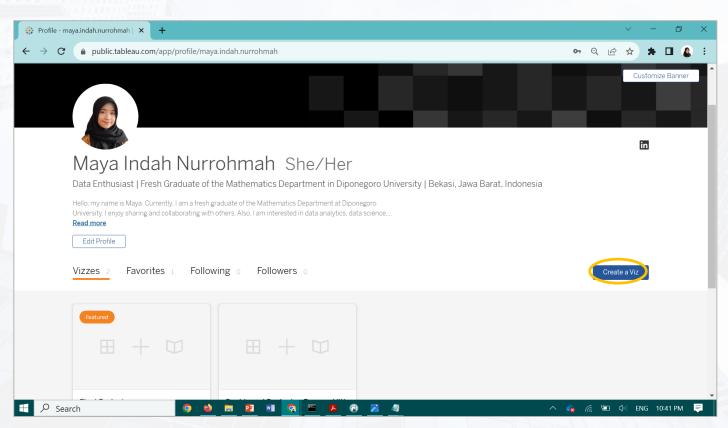
-	productname *	¹²³ totalamountfinal **
1	Cheese Stick	27,615,000
2	Choco Bar	21,190,400
3	Coffee Candy	19,711,800
4	Yoghurt	19,630,000
5	Oat	15,440,000
6	Crackers	13,680,000
7	Potato Chip	13,104,000
8	Thai Tea	11,982,600
9	Cashew	11,286,000
10	Ginger Candy	8,403,200

Jadi, diperoleh informasi bahwa terdapat 10 jenis produk yang terjual dan **produk** dengan total amount terbanyak yaitu cheese stick (Rp 27.615.000)

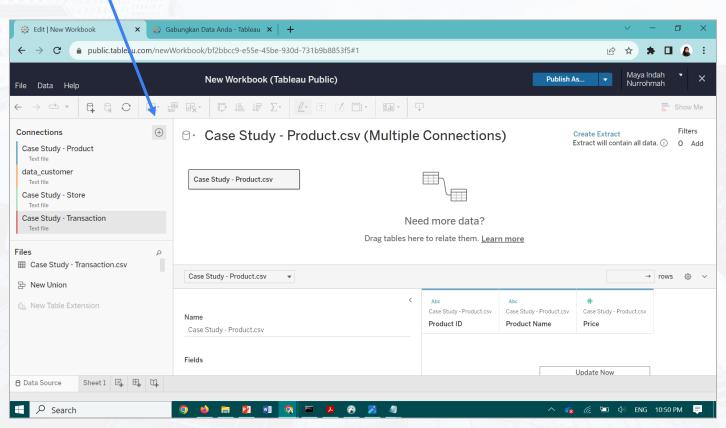


Challenge 3

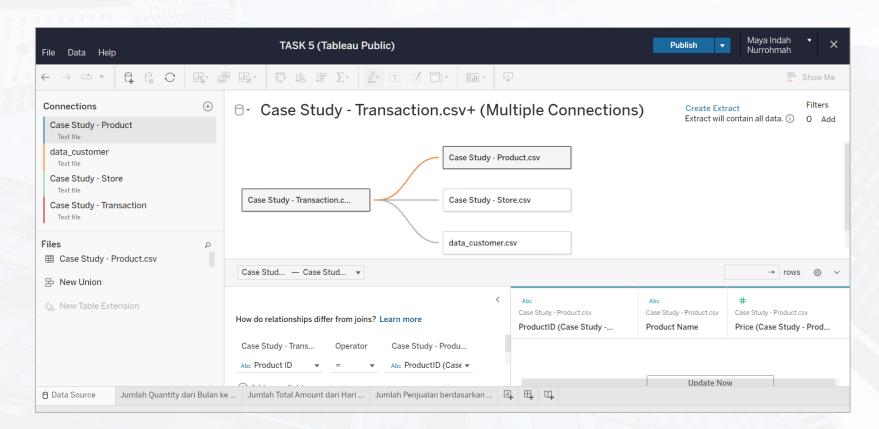














Challenge 4

Membuat dashboard di Tableau Public

Rakamin Project-Based Intern: Data Scientist oleh Maya Indah Nurrohmah Academy **Total Quantity Total Amount DASHBOARD PENJUALAN TAHUN 2022** Rp 162,043,000.00 18,296.00 item Pilih Nama Store: Pilih Bulan: Pilih Nama Produk: JUMLAH QUANTITY DARI BULAN KE BULAN TOTAL QUANTITY BERDASARKAN PRODUK Date Product Name 1.589 1.592 3К 1.499 1,560 2,626 2.408 1,554 1.532 1.492 1,441 1,453 1,422 2,097 1.963 1.841 2K Total Qu 1,092 Thai Tea Ginger Choco Bar Coffee Cheese Crackers Potato Oat Yoghurt August September October November December Candy TOTAL AMOUNT BERDASARKAN NAMA STORE JUMLAH TOTAL AMOUNT DARI HARI KE HARI Bonafid Gita Ginara Lingga Prestasi Utama Harapan Rp 25,294,100 Baru 6M (Rp) Prima Kota Prima Kelapa Dua Priangan Sinar Harapan Rp 21,882,600 Prima Tendean Buana Buana Indah 24 26 28 Day of Date



Challenge 5

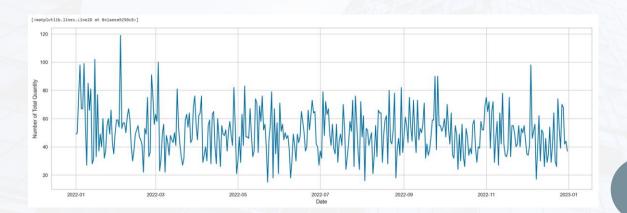
Membuat model prediktif timeseries dan clustering



Memanggil dataset

data_transactions_final_2 = pd.read_csv('data_transactions_final.csv', index_col=[0])
data_transactions_final_2.head()

data_untuk_timeseries = data_transactions_final_2.groupby('Date').agg({'Qty': 'sum'})
data_untuk_timeseries



	Qty
Date	
2022-01-01	49
2022-01-02	50
2022-01-03	76
2022-01-04	98
2022-01-05	67
•••	

01

Import dan Groupping
Dataset



```
from statsmodels.tsa.stattools import adfuller

def adf_test(dataset):
    dftest = adfuller(dataset, autolag = 'AIC')
    print("1. ADF : ",dftest[0])
    print("2. P-Value : ", dftest[1])
    print("3. Num Of Lags : ", dftest[2])
    print("4. Num Of Observations Used For ADF Regression:", dftest[3])
    print("5. Critical Values :")
    for key, val in dftest[4].items():
        print("\t",key, ": ", val)
adf_test(data_untuk_timeseries['Qty'])
```

02

Memeriksa Stationarity



```
from pmdarima import auto arima
stepwise fit = auto arima(data untuk timeseries['Qty'], trace=True,
suppress warnings=True)
Performing stepwise search to minimize aic
 ARIMA(2,0,2)(0,0,0)[0] intercept : AIC=3098.997, Time=0.51 sec
ARIMA(0,0,0)(0,0,0)[0] intercept : AIC=3094.267, Time=0.01 sec
ARIMA(1,0,0)(0,0,0)[0] intercept : AIC=3096.267, Time=0.05 sec
ARIMA(0,0,1)(0,0,0)[0] intercept : AIC=3096.267, Time=0.12 sec
 ARIMA(0,0,0)(0,0,0)[0]
                         : AIC=3933.778, Time=0.02 sec
ARIMA(1,0,1)(0,0,0)[0] intercept : AIC=3098.260, Time=0.09 sec
Best model: ARIMA(0,0,0)(0,0,0)[0] intercept
Total fit time: 0.797 seconds
```

03



```
print(data_untuk_timeseries.shape)
train=data_untuk_timeseries.iloc[:-30]
test=data_untuk_timeseries.iloc[-30:]
print(train.shape,test.shape)

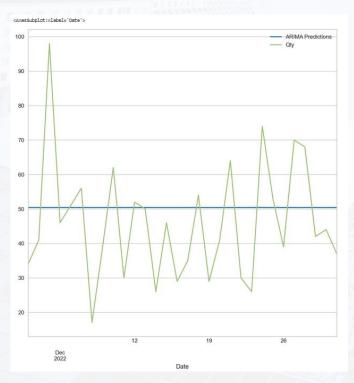
(365, 1)
(335, 1) (30, 1)
```



Split dan Train Data

```
# Train test split
from statsmodels.tsa.arima_model import ARIMA
model=sm.tsa.arima.ARIMA(train['Qty'],order=(0,0,0))
model=model.fit()
```





```
start=len(train)
end=len(train)+len(test)-1
pred=model.predict(start=start,end=end,typ='levels').rename('ARIMA Predictions')
pred.plot(legend=True)
test['Qty'].plot(legend=True)
```

```
from sklearn.metrics import mean_squared_error
from math import sqrt
test['Qty'].mean()
rmse=sqrt(mean_squared_error(pred,test['Qty']))
print(rmse)

17.549888906746727
```

05





Melakukan import dataset hasil left join dan memilih fitur untuk dilakukan clustering

```
# Memanggil dataset

data_transactions_final = pd.read_csv('data_transactions_final.csv', index_col=[0])
data_transactions_final.head()
```

```
data_untuk_clustering = data_transactions_final[['CustomerID','TransactionID',
                                                  'Qty','TotalAmount']]
data_untuk_clustering
      CustomerID TransactionID Qty TotalAmount
             328
   0
                       TR11369
                                            30000
             165
                       TR16356
                                            70000
             183
   2
                        TR1984
                                            35200
   3
             160
                       TR35256
                                            61600
             386
                       TR41231
                                            10000
   •••
```



Menyesuaikan tipe data dalam dataset



data untuk clustering.info() <class 'pandas.core.frame.DataFrame'> Int64Index: 5020 entries, 0 to 5019 Data columns (total 4 columns): Column Non-Null Count Dtype CustomerID 5020 non-null object TransactionID 5020 non-null object int64 5020 non-null 0tv TotalAmount 5020 non-null int64 dtypes: int64(2), object(2) memory usage: 196.1+ KB





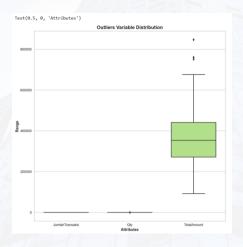
Groupby berdasarkan
CustomerID dan beberapa
aggregation

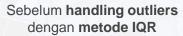
Jumla	hTransaksi	Qty	TotalAmount
nerID			
1	17	60	623300
2	13	57	392300
3	15	56	446200
4	10	46	302500
5	7	27	268600

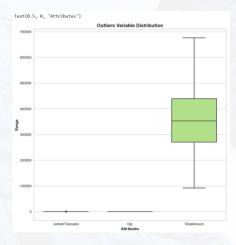


Melakukan handling outliers dengan metode IQR

Mengatasi
Outliers







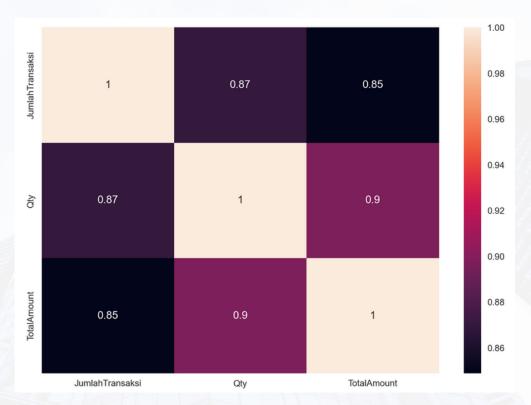
Sesudah handling outliers dengan metode IQR





keterhubungan antar

variabel dalam dataset



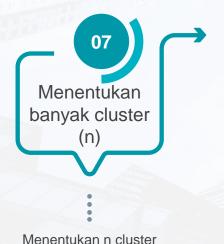


Melakukan standarisasi dengan MinMaxScaler



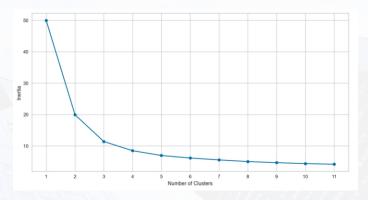
```
# Mengubah Variabel Data Frame Menjadi Array
data untuk clustering array = np.array(data untuk clustering)
print(data untuk clustering array)
            60 623300]
            57 392300]
            56 446200]
            68 587200]
            42 423300]
            42 439300]]
# Menstandarkan Ukuran Variabel
scaler = MinMaxScaler()
data untuk clustering scaled = scaler.fit transform(data untuk clustering array)
data untuk clustering scaled
array([[0.77777778, 0.79365079, 0.90943332],
       [0.55555556, 0.74603175, 0.51395309],
       [0.66666667, 0.73015873, 0.60623181],
       [0.83333333, 0.92063492, 0.84762883],
       [0.44444444, 0.50793651, 0.56702619],
       [0.55555556, 0.50793651, 0.59441876]])
```



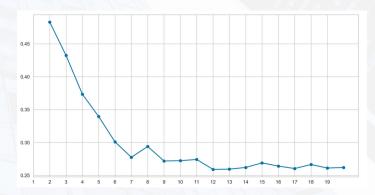


dengan Elbow Method dan melakukan evaluasi dengan Silhouette Score Jadi untuk data yang diberikan, disimpulkan bahwa jumlah cluster optimal untuk data tersebut adalah 3 (n=3) dengan silhouette score yaitu 0.43.

Elbow Method:



Silhouette Score:





Cluster 0

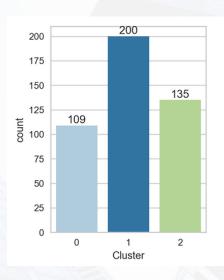
Cluster 0 merupakan kelompok yang memiliki customer paling sedikit yaitu 109 orang

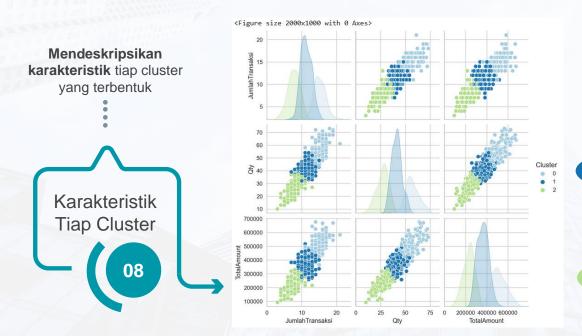
Cluster 1

Cluster 1 merupakan kelompok yang memiliki customer paling banyak yaitu 200 orang

Cluster 2

Cluster 2 merupakan kelompok yang memiliki customer sebanyak 135 orang





Cluster 0

- Kelompok customer yang paling banyak melakukan transaksi
- · Membeli item dengan jumlah banyak
- Menghasilkan total amount paling tinggi
- Kelompok ini akan mendatangkan keuntungan ke perusahaan
- Memberikan diskon dan penawaran lain yang ditargetkan untuk kelompok cluster 0 akan meningkatkan transaksi dan pembelian sehingga memaksimalkan keuntungan perusahaan.

Cluster 1

- Kelompok customer dengan jumlah transaksi rata-rata
- · Membeli item dengan jumlah rata-rata
- Menghasilkan total amount sedang

Cluster 2

- Kelompok customer dengan jumlah transaksi sedikit
- · Membeli item dengan jumlah sedikit
- · Menghasilkan total amount rendah



Video Presentasi Dan File-File Pengerjaan



http://bit.ly/DriveFPKalbeMaya

https://bit.ly/VideoPresentasiFPKalbeMaya

Thank You



